

Avertissement !

J'attends de vous un travail personnel. En conséquent :

- l'utilisation d'une IA générative est strictement interdite et sera sanctionnée
- les seules bibliothèques python autorisées sont `pandas`, `matplotlib` et `numpy`
L'utilisation des fonctions et/ou de méthodes exotiques, ie, non présentes dans les sujets de TP, sont proscrites.
- tous vos travaux seront soumis à un détecteur de plagiat et d'utilisation d'une IA générative

Extrait du règlement de l'IUT :

L'utilisation [...] d'outils d'intelligence artificielle (comme ChatGPT ou autre) lors de la production de travaux personnels ou de groupe de toute nature, susceptible de faire l'objet d'une évaluation, est considérée comme une fraude passible de poursuites disciplinaires

En cas de fraude ou tentative de fraude commise à l'occasion d'une épreuve d'examen, la Charte des examens de l'Université s'applique.

Pour information, les sanctions possibles

1. l'avertissement ;
2. Le blâme ;
3. l'exclusion de l'université pour une durée maximum de 5 ans. Cette sanction peut être prononcée avec sursis si l'exclusion n'excède pas 2 ans.
4. l'exclusion définitive de l'université ;
5. l'exclusion de tout établissement public d'enseignement supérieur pour une durée maximum de 5 ans ;
6. l'exclusion définitive de tout établissement public d'enseignement supérieur.

Problématiques

Nous travaillons avec le jeu de données `Indice_qualité_de_lair_-_ATM0.csv` qui traite de la qualité de l'air en région Auvergne-Rhône-Alpes.

Objectifs.

- Utiliser la méthode des k plus proches voisins pour effectuer des prédictions sur la qualité de l'air ;
- vérifier l'efficacité de cette méthode, c'est-à-dire vérifier si la connaissance des concentrations de certaines substances permettent de prédire le niveau de la qualité de l'air.

Caractéristiques du fichier.

- séparateur : `;`
- encodage : `latin1`

Variables utilisées.

- variables actives : `conc_no2`, `conc_so2`, `conc_o3`, `conc_pm10`, `conc_pm25` ;
- variables complémentaires : `code_qual`, `lib_zone`, `x_wgs84`, `y_wgs84` ;

Les *variables actives* sont les variables utilisées pour le calcul des distances dans la méthode des k plus proches voisins et les variables complémentaires donnent des informations utiles pour répondre à notre problématique mais n'entrent pas directement dans les calculs.

Travail demandé

Charger le jeu de données

Puis, le transformer pour ne garder que les variables actives et complémentaires.

Carte de prédiction

1. Étudier les corrélations entre les différentes variables actives et en choisir deux qui, selon vous, apportent le plus d'information (ce sera à justifier).
2. Représenter le nuage de points associé à ces deux variables en utilisant le code couleur donnant la qualité de l'air.
3. Réaliser une carte des prédictions en utilisant la méthode des k plus proches voisins. Attention à bien tenir compte de toutes les variables pour vos calculs.

Apprentissage supervisé

1. Créer un jeu d'apprentissage et un jeu de test : il y a plusieurs mesures pour chaque commune.
 - le jeu d'apprentissage sera constitué de la première occurrence de chaque commune ;
 - le jeu de test sera constitué de la dernière occurrence de chaque commune.
2. En utilisant les coordonnées GPS `x_wgs84` et `y_wgs84`, tracer la carte **géographique** du jeu de test en respectant le code couleur de la qualité de l'air.
3. (a) Pour chaque ligne du jeu de test, prédire le code qualité de l'air, en utilisant la méthode des k plus proches voisins (attention à utiliser toutes les variables!).
(b) Combien d'erreurs de prédictions ont été faites ?
4. Quel résultat obtient-on si l'on prend les voisins *géographiques*, c'est-à-dire si l'on calcule les distances avec les positions GPS `x_wgs84` et `y_wgs84` ?
Comparer avec les résultats précédents.

Conclusion.

Conclure, suivant vos résultats sur l'efficacité et la pertinence des méthodes utilisées.

À rendre

Le notebook `jupyter` correspondant (qualité de l'air).

Les notebook seront commentés et vous devrez justifier et/ou expliquer vos choix et la qualité de la rédaction et la pertinence des commentaires seront prises en compte dans l'évaluation.

En analyse de données, les représentations graphiques sont souvent très utiles pour résumer les données ou les résultats obtenus. Aussi, n'hésitez pas à illustrer vos propos ou les résultats d'une analyse par un graphique si vous jugez cela pertinent. Par contre, un soin particulier devra y être apporté (titre, légende, axes, couleurs, etc.)

Fonctions ou méthodes `pandas` utiles

- `DataFrame.drop_duplicates(subset=None, keep='first', inplace=False, ignore_index=False)`
voir la documentation

Code couleur

Nous pourrions utiliser le code couleur suivant :

<code>code_qual</code>	1	2	3	4	5	6
couleur python	<code>blue</code>	<code>green</code>	<code>yellow</code>	<code>red</code>	<code>brown</code>	<code>darkviolet</code>

Ressources

- pandas.pydata.org/
- pour embellir vos graphiques, le fichiers des contours des régions `auvergne.csv` et `rhone-alpes.csv` pourront éventuellement vous être utiles.

